

Análise Exploratória — Cabeçalhos de Notas Fiscais

Avaliação da base NF.csv

Marco A. Silva

2026-07-13

Índice

0.1	Avaliando arquivo FIS_NF.CSV	2
1	Iniciando Análise Exploratória	8
1.1	Avaliando prefixo TP	10
1.2	Avaliando prefixo CD	18
1.3	Cruzando informações	25
1.4	Avaliando prefixo DT	42
1.5	Avaliando prefixo VL	47
2	Conclusão	51

0.1 Avaliando arquivo FIS_NF.CSV

```
PosixPath('/Users/marcosilva/Projetos/FAMaringa/data')
```

Número de linhas: 35415

Número de colunas: 43

CD_EMPRESA	int64
NR_FATURA	int64
DT_FATURA	str
U_VERSION	str
CD_PESSOA	int64
CD_EMPFAT	int64
CD_GRUPOEMPRESA	int64
CD_OPERADOR	int64
DT_CADASTRO	str
NR_NF	int64
CD_SERIE	float64
DT_EMISSAO	str
TP_ORIGEMEMISSAO	int64
TP_MODALIDADEFISCAL	int64
TP_OPERACAO	str
TP_SITUACAO	str

CD_EMPRESAORI	float64
NR_TRANSACAOORI	float64
DT_TRANSACAOORI	str
CD_OPERACAO	int64
CD_CONDPGTO	int64
CD_MODELONF	float64
NR_PRE	float64
HR_SAIDA	str
DT_SAIDAENTRADA	str
CD_COMPVEND	int64
IN_FRETE	float64
CD_USUIMPRESSAO	float64
DT_IMPRESSAO	str
NR_IMPRESSAO	float64
PR_DESCONTO	float64
QT_FATURADO	int64
VL_TOTALPRODUTO	float64
VL_DESPACESSOR	float64
VL_FRETE	float64
VL_SEGURO	float64
VL_IPI	int64
VL_DESCONTO	float64
VL_TOTALNOTA	float64
VL_BASEICMSSUBS	int64
VL_ICMSSUBST	int64
VL_BASEICMS	float64
VL_ICMS	float64
dtype: object	

IN_FRETE	100.0000
CD_USUIMPRESSAO	98.3114
DT_IMPRESSAO	98.3114
NR_IMPRESSAO	98.3114
CD_MODELONF	50.9728
NR_PRE	15.2252
VL_SEGURO	11.7182
VL_FRETE	11.7182
VL_DESPACESSOR	11.7182
CD_SERIE	0.0395
DT_TRANSACAOORI	0.0028
NR_TRANSACAOORI	0.0028
CD_EMPRESAORI	0.0028
PR_DESCONTO	0.0000

```
VL_TOTALPRODUTO      0.0000
dtype: float64
```

A análise descritiva apresenta bons insights para as colunas do tipo VL (Valor).

- VL_TOTALPRODUTO e VL_TOTALNOTA: Apresentam um desvio padrão relativamente alto, com valor máximo igual a R\$603.747,69
- VL_DESPACESSOR e VL_DESCONTO: É preciso avaliar melhor os dados pois a maioria apresenta valor igual a Zero.
- VL_FRETE : Frete não cobrado em pelo menos metade dos registros.
- VL_SEGURO, VL_BASEICMSSUBS, VL_ICMSSUBST e VL_IPI : Todos os registros estão com valor igual Zero.
- VL_BASEICMS e VL_ICMS: Apresentam registros válidos e compatíveis com os valores das notas.

```
VL_DESPACESSOR
0.00      31259
99.00         2
44.90         2
46.95         1
10.90         1
Name: count, dtype: int64
```

A coluna VL_DESPACESSOR contém 11,7% de valores ausentes, o nome não é claro sobre a origem porém o padrão VL indica ser algum Valor/Custo. Há apenas 6 registros não zerados ou não nulos em todo o dataset.

Avaliando os únicos registros desse dado em todo o conjunto, nota-se que ele faz parte da Base de Cálculo do ICMS, dessa forma, não pode ser ignorado muito menos excluído.

Sendo assim, como a coluna referente ao Frete contém a mesma quantidade de registros ausentes, vamos completar os dados ausentes com Zero.

Para fins de cálculo, essa coluna vai ser tratada como despesa considerando a sua participação no ICMS.

As colunas CD_MODELONF, CD_USUIMPRESSAO e NR_IMPRESSAO, referentes a Códigos e Números de registro, apresentam a grande maioria dos dados ausentes. Vamos avaliar a necessidade desses dados antes de afirmar a sua exclusão da base.

Total de registros para NR_IMPRESSAO: 598

Quantidade de registros únicos para NR_IMPRESSAO: 4

NR_IMPRESSAO

1.0 535

2.0 55

3.0 7

4.0 1

Name: count, dtype: int64

Total de registros para CD_USUIMPRESSAO: 598

Quantidade de registros únicos para CD_USUIMPRESSAO: 19

CD_USUIMPRESSAO

11124.0 340

11171.0 126

939.0 34

1138.0 29

1174.0 24

1129.0 10

1183.0 8

465.0 6

1161.0 5

468.0 2

1172.0 2

1132.0 2

557.0 2

598.0 2

11032.0 2

1180.0 1

927.0 1

457.0 1

600.0 1

Name: count, dtype: int64

CD_MODELONF

912.0 17307

911.0 56

Name: count, dtype: int64

CD_MODELONF e NR_PRE não apresentam informação relevante.

A coluna DT_IMPRESSÃO é redundante.

A coluna CD_SERIE apresenta poucos valores ausentes, por se tratar de um código de série, é presumido que produtos de mesma série possuem características iguais.

```
VL_TOTALPRODUTO
34.72    9
43.23    3
71.14    1
37.81    1
Name: count, dtype: int64
```

```
VL_TOTALPRODUTO = 34.72 | ocorrências = 9
CD_SERIE
1.0      19
Name: count, dtype: int64
```

```
VL_TOTALPRODUTO = 43.23 | ocorrências = 3
CD_SERIE
1.0      7
Name: count, dtype: int64
```

```
VL_TOTALPRODUTO = 71.14 | ocorrências = 1
Series([], Name: count, dtype: int64)
```

```
VL_TOTALPRODUTO = 37.81 | ocorrências = 1
Series([], Name: count, dtype: int64)
```

Foram encontrados 4 valores distintos para esses registros, 2 deles não apresentam código de série enquanto os outros 2 apresentam código de série igual a 1.0. Dessa forma, seguindo o padrão, vamos preencher os valores ausentes com '1.0'

```
CD_EMPRESAORI
6.0    35414
Name: count, dtype: int64
```

0.1.1 Tratamentos necessários

- Colunas 'DT_' (Data) encontram-se como 'str' e precisam ser convertidas para 'DateTime'.
- Coluna 'HR_SAIDA' está no formato 'str' mas é 'DateTime'.
- A coluna IN_FRETE não há registros então pode ser deletado.
- CD_MODELONF, CD_USUIMPRESSAO e NR_IMPRESSAO não apresentam informações relevantes, e devido à grande quantidade de registros nulos também vão ser deletados.

- U_VERSION não apresenta informação relevante portanto vai ser deletado.
- VL_SEGURO, VL_FRETE e VL_DESPACESSOR são relevantes, os dados nulos vão ser completados com Zero.
- DT_IMPRESSAO vai ser deletado pela grande quantidade de valores nulos, e também por sua redundância uma vez que é igual à DT_EMISSAO.
- DT_TRANSACAOORI vai ser deletado por sua redundância uma vez que é igual à DT_EMISSAO.
- NR_PRE vai ser deletado por não trazer nenhuma informação relevante e grande quantidade de valores nulos.
- CD_EMPRESAORI apenas um registro nulo, porém todos há apenas um valor para essa coluna, então preencher com padrão '6'.
- CD_SERIE preencher valores ausentes com 1.
- CD_EMPRESAORI preencher valores ausentes com 6.
- A coluna NR_TRANSACAOORI apresenta um único registro ausente. Como o registro não tem nenhum tipo de Valor, será deletado somente esse registro.
- Colunas [CD_SERIE, CD_EMPRESAORI, NR_TRANSACAOORI,] encontram-se como 'float64', podem ser convertidas para int64 para melhorar a semântica.


Caso o volume de dados para essa coluna com prefixo CD , TP e NR se torne muito grande, é preferível que seja transformado em int32 para economizar memória e melhorar o desempenho.

```
NR_TRANSACAOORI    1
CD_EMPRESA          0
CD_CONDPGTO         0
DT_SAIDAENTRADA     0
CD_COMPVEND         0
dtype: int64
```

1 Iniciando Análise Exploratória


1.0.1 Distribuição do VL_TOTALNOTA

Histograma em escala logarítmica para evidenciar a concentração de valores totais das notas, que em sua maioria estão abaixo de R\$ 500, com uma cauda longa de outliers de alto valor.




1.0.2 Boxplot do VL_TOTALNOTA

Boxplot em escala log para destacar a mediana, os quartis e a grande quantidade de outliers de alto valor, já identificados nas estatísticas descritivas (máximo de R\$ 603.747,77).




1.0.3 Distribuição da QT_FATURADO

Histograma em escala log no eixo Y para visualizar a concentração de quantidades faturadas nas notas, que em sua maioria são iguais a 1 ou 2, com outliers chegando a 1.527.



1.0.4 Série temporal de faturamento (VL_TOTALNOTA por DT_FATURA)

O gráfico mostra a evolução diária do valor total das notas faturadas. DT_FATURA foi identificada como a melhor referência temporal por acompanhar o ciclo efetivo de faturamento, e a série permite identificar tendências e picos no período coberto pela base.



1.1 Avaliando prefixo TP

TP_ORIGEMEMISSAO

[2 1]

=====

TP_MODDCTOFISCAL

[57 55 81]

=====

TP_OPERACAO

<StringArray>

['E', 'S']

Length: 2, dtype: str

=====

TP_SITUACAO

<StringArray>

['E', 'C', 'X']

Length: 3, dtype: str

=====

TP_ORIGEMEMISSAO

1 52.284407

2 47.715593

Name: proportion, dtype: float64

TP_MODDCTOFISCAL

55 52.561134

57 46.831761

```
81      0.607105
Name: proportion, dtype: float64
```

```
TP_OPERACAO
E      52.702321
S      47.297679
Name: proportion, dtype: float64
```

```
TP_SITUACAO
E      97.323093
X       1.524821
C       1.152087
Name: proportion, dtype: float64
```


As colunas com prefixo TP indicam claramente referenciar a TIPO de alguma coisa, e trazem alguns pontos interessantes.

- TP_MODDCTOFISCAL aparenta ser algum código interno para indicar o Modelo do Documento Fiscal.
- TP_OPERACAO indica claramente o tipo de operação como sendo Entrada e Saída.
- TP_SITUACAO eu vou inferir que o significado dos dados são Executada/Válida (E), Excluído/Inválido (X), Cancelado (C).
- TP_ORIGEMEMISSAO de acordo com o nome indica a origem, mas ainda não ficou claro, vamos fazer alguns cruzamentos de dados para tentar identificar.

De todas essas colunas, apenas TP_SITUACAO que contém os dados agregados em sua grande maioria em um único tipo de registro. As demais colunas apresentam uma distribuição quase uniforme.


1.1.1 Distribuição TP_SITUACAO

Gráfico de barras mostrando que a grande maioria dos registros está em situação E (Executada/Válida), com uma pequena parcela de X (Excluído) e C (Cancelado).




1.1.2 Distribuição TP_OPERACAO

Distribuição entre Entrada (E) e Saída (S), evidenciando que as saídas têm maior participação que as entradas na base de notas fiscais.




1.1.3 Distribuição TP_MODDCTOFISCAL

O gráfico mostra os três tipos documentais (55, 57, 81), evidenciando que 55 é o mais frequente, seguido de 57 com volume expressivo, e 81 com presença residual.




1.1.4 Distribuição TP_ORIGEMEMISSAO

Distribuição entre as origens de emissão (1 e 2), mostrando uma distribuição quase uniforme entre as duas origens.




1.1.5 Heatmap: TP_MODDCTOFISCAL x TP_OPERACAO

O cruzamento evidencia que o tipo documental 55 aparece tanto em entrada quanto saída (predominando saída), enquanto 57 e 81 são exclusivamente de entrada, reforçando a leitura dos três macroblocos documentais.




1.1.6 Heatmap: TP_MODALTOFISCAL x TP_SITUACAO

A tabela mostra a distribuição de situação (E, C, X) dentro de cada tipo documental. O tipo 55 concentra todos os cancelamentos (C), enquanto o tipo 57 tem uma parcela relevante de excluídos (X).



1.1.7 Heatmap: TP_SITUACAO x TP_OPERACAO

O cruzamento entre situação e operação confirma que a grande maioria dos registros está em situação E (Executada/Válida), com poucos cancelamentos concentrados em saídas.



1.2 Avaliando prefixo CD

CD_EMPRESA

[6]

CD_PESSOA

[1738191 2067439 2477869 ... 2488672 2488683 2488685]

CD_EMPFAT

[6]

CD_GRUPOEMPRESA

[6]

CD_OPERADOR

[11032 11106 11134 831 557 11148 11120 465 11118 1173 11159 1161
 1132 1148 11145 927 933 1138 1180 1129 939 468 11124 1172
 1176 922 598 589 457 11142 1174 3356 1183 1175 11171 11139
 11127 1181 11122 1184 600 11062 1116 11059 638]

```
CD_SERIE
[ 1 10  9  2 14  0 157  4  3 60 36  5 40 20 28  8 22  6
 51]
```

```
=====
```

```
CD_EMPRESAORI
[6]
```

```
=====
```

```
CD_OPERACAO
[1353 1300 5110 1994 1355 1933 9998  46 1354 1600 1601  231  233 5920
 560 1800  237  499 9143  408 5950 1982  410 5108  129 1949 2911  306
 9950  716]
```

```
=====
```

```
CD_CONDPGTO
[  2  72  21 535 533 510 532 531 506  45  82 509 534 508
 507 536 505 503 501  37 585 586 540 504 348 502  83  18
 512 515 511  1 550 530  80 5591 5593  3 999]
```

```
=====
```

```
CD_COMPVEND
[ 3 854 60 788  89 890 852 856  69  50 855 889 577  56 857 865 150 758
 96  51]
```

```
=====
```

Quantidade de dados únicos em CD_EMPRESA -> 1

CD_EMPRESA

6 100.0

Name: proportion, dtype: float64

Quantidade de dados únicos em CD_PESSOA -> 16046

CD_PESSOA

1738191 8.013780

1905365 6.672502

2067439 5.469588

1720944 3.196476

2485702 2.806800

...

2476131 0.002824

2102344 0.002824

2476132 0.002824

2476133 0.002824
2488685 0.002824
Name: proportion, Length: 16046, dtype: float64

Quantidade de dados únicos em CD_EMPFAT -> 1
CD_EMPFAT
6 100.0
Name: proportion, dtype: float64

Quantidade de dados únicos em CD_GRUPOEMPRESA -> 1
CD_GRUPOEMPRESA
6 100.0
Name: proportion, dtype: float64

Quantidade de dados únicos em CD_OPERADOR -> 45
CD_OPERADOR
11134 30.764669
11106 14.432145
11120 13.497487
927 11.865364
933 10.902468
831 4.108545
11032 3.908059
1161 1.863670
11059 1.338454
11124 1.228328
465 0.722878
11159 0.632518
598 0.561925
11145 0.553453
1129 0.533687
11171 0.468741
1132 0.463094
1183 0.367086
557 0.240018
11118 0.186367
11148 0.175072
1180 0.169425
468 0.146835
939 0.121421
1176 0.101655
1138 0.093183
457 0.081889

922	0.079065
1174	0.064946
1181	0.059299
589	0.056475
1175	0.056475
1148	0.048004
11139	0.019766
638	0.016942
1172	0.016942
1173	0.014119
3356	0.008471
11122	0.008471
11142	0.005647
1116	0.005647
11127	0.002824
1184	0.002824
600	0.002824
11062	0.002824

Name: proportion, dtype: float64

Quantidade de dados únicos em CD_SERIE -> 19

CD_SERIE

2	49.830575
1	30.979274
10	8.138025
9	3.286836
0	2.120630
3	2.064155
4	1.764839
14	1.197267
60	0.434856
157	0.059299
20	0.042356
36	0.019766
5	0.019766
6	0.011295
40	0.008471
22	0.008471
28	0.005647
8	0.005647
51	0.002824

Name: proportion, dtype: float64

```
Quantidade de dados únicos em CD_EMPRESAORI -> 1
CD_EMPRESAORI
6      100.0
Name: proportion, dtype: float64
```

```
Quantidade de dados únicos em CD_OPERACAO -> 30
CD_OPERACAO
9998      44.903146
1300      25.792060
1355      11.715706
1600       7.463150
 46       3.408257
1994       1.567177
5110       1.558706
1353       1.270684
1933       0.607105
1601       0.333202
 231       0.273903
1800       0.254137
 560       0.158130
9143       0.158130
 233       0.152482
5108       0.129892
 499       0.090360
5920       0.084712
5950       0.031061
 410       0.011295
 408       0.008471
 129       0.005647
1354       0.002824
 237       0.002824
1982       0.002824
1949       0.002824
2911       0.002824
 306       0.002824
9950       0.002824
 716       0.002824
Name: proportion, dtype: float64
```

```
Quantidade de dados únicos em CD_CONDPGTO -> 39
CD_CONDPGTO
 72      35.093466
 21      22.276501
```

2	15.976732
535	11.492630
82	3.323544
586	2.775738
533	2.425594
532	2.258994
534	0.920540
37	0.609928
45	0.550630
585	0.440504
536	0.254137
531	0.220252
503	0.129892
18	0.127068
510	0.115773
505	0.112950
83	0.101655
502	0.101655
501	0.093183
540	0.079065
504	0.079065
506	0.064946
1	0.064946
507	0.050827
508	0.045180
512	0.039532
80	0.033885
509	0.031061
530	0.028237
550	0.022590
348	0.014119
5591	0.011295
511	0.008471
5593	0.008471
999	0.008471
515	0.005647
3	0.002824

Name: proportion, dtype: float64

Quantidade de dados únicos em CD_COMPVEND -> 20

CD_COMPVEND

60	47.978201
3	47.464280

854	3.286836
89	0.584515
150	0.129892
889	0.101655
50	0.093183
855	0.093183
852	0.087536
865	0.059299
788	0.050827
856	0.016942
577	0.016942
890	0.008471
69	0.008471
857	0.008471
56	0.002824
758	0.002824
96	0.002824
51	0.002824

Name: proportion, dtype: float64

Para colunas com prefixo CD

Algumas contam com o mesmo padrão que foi identificado no arquivo NFITEM, como por exemplo as colunas relacionadas à empresa, CD_EMPRESA, CD_EMPFAT e CD_GRUPOEMPRESA. Todas com um único registro, indicando que a base de dados é referente a apenas uma das empresas do grupo.

Já as outras colunas indicam ser algum tipo de nomenclatura interna da empresa, algumas são possíveis de inferir o que indicam, mas de qualquer forma será necessário cruzar algumas informações para obter insights relevantes a respeito do conteúdo dessas colunas.


- CD_PESSOA contém 16046 registros únicos, sendo que o registro de maior frequência aparece em 8% dos dados. Essa coluna pode indicar um código ligado a um cliente/cadastro.
- CD_SERIE contém 19 registros únicos porém a maioria dos dados estão concentrados nos códigos 1 e 2.
- CD_OPERADOR contém 45 registros únicos com a maioria dos dados concentrados em apenas 5 deles.
- CD_OPERACAO contém 30 registros únicos com a maioria dos dados concentrados em apenas 3 deles.

- CD_CONDPGTO contém 39 registros únicos com a maioria dos dados concentrados em apenas 4 deles.
- CD_COMPVEND contém 20 registros únicos com a maioria dos dados concentrados em apenas 2 deles.

Todos esses códigos não vão trazer grandes informações se forem observados de forma isolada. Para conseguir mais informação desses dados será necessário cruzar com outras colunas para ver como eles se encaixam.

1.2.1 Cardinalidade das colunas com prefixo CD

O gráfico mostra quantos valores únicos cada coluna CD possui. Colunas com apenas 1 valor único (CD_EMPRESA, CD_EMPFAT, CD_GRUPOEMPRESA, CD_EMPRESAORI) não agregam segmentação. Já CD_PESSOA (16.046 únicos) e NR_NF são identificadores individuais.



1.3 Cruzando informações

1.3.1 Começar pelo bloco estrutural do documento

Esse é o melhor ponto de partida porque ele conecta:

- TP_MODDCTOFISCAL
- TP_OPERACAO

- TP_SITUACAO
- CD_SERIE
- NR_NF

A ideia aqui é entender:

- Que tipos de documento existem.
- Quais são de entrada e quais são de saída.
- Quais concentram cancelamentos/exclusões.
- Se a série separa tipos documentais ou fluxos.

O código 55 aparece em entrada e saída:

- E / E = 1831
- S / E = 16303
- além de alguns casos C e X

Isso mostra que o 55 é o tipo documental mais “geral” da base, porque participa dos dois fluxos:

- saída, com peso muito maior;
- entrada, com volume menor, mas ainda relevante.

A leitura mais provável é que o 55 esteja ligado ao documento fiscal principal de mercadoria. Não dá para cravar oficialmente só pelos dados, mas a distribuição é bem compatível com isso.

O mais importante aqui é: 55 não significa apenas venda. Ele aparece também em entrada. Então, para análise futura $TP_MODDCTOFISCAL = 55$ não pode ser tratado sinônimo automático de faturamento.

O 57 aparece somente em entrada:

- E / E = 16121
- E / X = 464
- nenhum caso em saída

Isso é um padrão muito limpo, pois sugere fortemente que o 57 representa um documento que, neste recorte, está sendo tratado como documento de entrada. Pelo que foi observado em NFITEM, isso conversa muito bem com os lançamentos de:

- frete.
- serviço de transporte.
- itens sem TIPI de produto clássico.

Então a inferência mais forte aqui é que 57 parece ser um tipo documental ligado a transporte/serviço tomado, e não a faturamento de venda.

O 81 também aparece somente em entrada:

- E / E = 211
- E / X = 4

Ele é pequeno em volume, mas muito consistente no padrão. Como também é só entrada, ele parece representar outro tipo documental não comercial de saída.

Pelo que apareceu antes, há uma boa chance de ele estar ligado a algum tipo de documento de serviço, possivelmente diferente do 57.

Na prática essa primeira tabela permite separar a base em três blocos documentais bem diferentes:

- 55 = documento híbrido, mas majoritariamente de saída
- 57 = documento exclusivamente de entrada
- 81 = documento exclusivamente de entrada

Ou seja, a estrutura documental do NF já começa a se dividir naturalmente entre:

- um bloco com cara de operação comercial de mercadoria;
- e dois blocos com cara de entrada de documentos acessórios / serviços.

Aqui a série começa a ganhar contexto.

A principal conclusão dessa tabela é:

CD_SERIE não deve ser interpretado sozinho. O significado da série depende do par:

- TP_MODDCTOFISCAL
- TP_OPERACAO

1.3.1.0.1 Série 2

A série 2 é a mais importante da base dentro do 55:

- 55 / S = 16122
- 55 / E = 1241
- 57 / E = 284

Ela concentra o coração do fluxo de 55, especialmente o de saída. Isso sugere que:

- série 2 é a principal série operacional do documento 55.
- e provavelmente carrega o maior bloco do faturamento comercial.

Como ela também aparece em 55 / E, isso reforça uma ideia importante: a série não é “entrada” ou “saída” por si só. Ela precisa ser lida junto com o tipo documental e a operação.

1.3.1.0.2 Série 1

A série 1 também chama muita atenção:

- 57 / E = 10717
- 81 / E = 215
- 55 / E = 39

Aqui a história é diferente. A série 1 está fortemente associada a entrada, principalmente com 57.

Isso sugere que a série 1 funciona quase como uma série padrão para documentos de entrada não comerciais de saída.

1.3.1.0.3 Série 9

A série 9 é interessante porque aparece dos dois lados dentro do 55:

- 55 / E = 581
- 55 / S = 582
- 57 / E = 1

Ela parece ter um comportamento mais “espelhado” ou “misto”. Não domina a base, mas claramente não é uma série de uso único. Merece observação porque pode representar um fluxo operacional específico.

1.3.1.0.4 Séries 3, 4, 10, 14, 60 etc.

Essas séries aparecem com peso menor, mas ajudam a perceber uma coisa importante:

- várias séries estão concentradas em 57 / E.
- portanto, as séries também parecem funcionar como subgrupos do tipo documental.

Em especial:

- 10 / 57 / E = 2882
- 3 / 57 / E = 685
- 4 / 57 / E = 625
- 14 / 57 / E = 424

Ou seja, o 57 está distribuído em várias séries, mas quase sempre no mesmo perfil: entrada.

Na prática essa segunda tabela mostra que:

- CD_SERIE tem valor analítico.
- Deve ser interpretado junto com o tipo documental e a operação
- Não deve ser interpretado como identificador isolado de natureza da nota.

Em outras palavras, a série ajuda a segmentar o fluxo, mas não define sozinha o que a nota representa.

CD_SERIE = 2 / TP_MODALITO_FISCAL = 55 / TP_OPERACAO = S

Esse é, claramente, o principal fluxo da base:

- 16122 notas com VL_TOTALNOTA = R\$8.783.739,45

O grupo domina completamente o dataset e tem todo o perfil de ser o principal bloco comercial de saída.

CD_SERIE = 2 / 55 / E

Esse segundo bloco também é muito relevante:

- 1241 notas com VL_TOTALNOTA = R\$1.836.484,74

É entrada com o mesmo tipo documental 55 e a mesma série principal. Isso sugere que parte relevante do ecossistema do 55 está associada a entrada, e não apenas a venda. Muito possivelmente esse bloco terá relação com:

- devoluções.
- entradas fiscais relacionadas ao mesmo tipo de documento.
- outros movimentos de regularização.

CD_SERIE = 1 / 55 / E

Esse é um caso muito importante:

- apenas 39 notas mas com VL_TOTALNOTA = R\$1.813.901,07

Ou seja, ticket médio altíssimo. Isso mostra que existem poucos documentos com muito valor agregado nesse fluxo. Eles merecem inspeção posterior, porque podem ser:

- documentos específicos de alto valor.
- ajustes.
- operações concentradas.
- algum tipo de entrada especial.

CD_SERIE = 1 / 81 / E

Outro bloco bem expressivo:

- 215 notas com VL_TOTALNOTA = R\$1.745.364,77

É muito valor para pouco volume. Como 81 só aparece em entrada, esse grupo parece representar um fluxo de entrada bastante relevante financeiramente.

CD_SERIE = 1 / 57 / E

Esse bloco é o oposto em perfil:

- 10717 notas com VL_TOTALNOTA = R\$754.475,98

Aqui o volume é muito alto e o valor médio é baixo. Isso casa bem com uma hipótese de documentos de frete / transporte / serviços acessórios de menor valor unitário.

CD_SERIE = 9 / 55 / S

- 582 notas com VL_TOTALNOTA = R\$245.965,62

Parece um subfluxo menor de saída do documento 55.

CD_SERIE = 10 / 57 / E

2882 notas com VL_TOTALNOTA = R\$146.827,69

Outro subfluxo de entrada associado ao 57, com bastante volume e valor médio mais baixo.


Demais grupos

Os outros grupos têm menos peso relativo, mas confirmam o padrão geral:

- 57 está pulverizado em várias séries, sempre em entrada;
- 55 concentra o grande fluxo de saída;
- 81 aparece de forma pequena em volume, mas forte em valor.

1.3.2 VL_TOTALNOTA por combinação CD_SERIE / TP_MODDCTOFISCAL / TP_OPERACAO

O gráfico mostra o valor total das notas para as principais combinações de série, tipo documental e operação, evidenciando o domínio do fluxo S2 / 55 / S (saída comercial principal) e a relevância do fluxo S1 / 55 / E com alto ticket médio.



1.3.2.1 Leitura consolidada dos resultados até aqui

- O dataset de NF tem três macroblocos documentais.
 - 55: bloco principal, majoritariamente de saída, mas com entradas relevantes.
 - 57: bloco exclusivamente de entrada, muito volumoso e com cara de documentos acessórios/serviços/transporte
 - 81: bloco exclusivamente de entrada, pequeno em volume e forte em valor.
- A série ajuda a segmentar esses blocos
 - série 2 domina o fluxo principal do 55
 - série 1 domina boa parte dos fluxos de entrada em 57 e 81
 - outras séries parecem funcionar como subcanais ou subtipos documentais
- O fluxo comercial principal provavelmente está em 55 / S / SERIE 2
 - Esse é o melhor candidato ao núcleo de faturamento de saída.
- Há blocos de entrada relevantes que não podem ser ignorados

Especialmente:

- 55 / E
- 57 / E
- 81 / E

1.3.2.2 Hipóteses

- TP_MODDCTOFISCAL 55 = documento principal de mercadoria, com saída dominante
- TP_MODDCTOFISCAL 57 = documento de entrada ligado a transporte/serviço/acessório
- TP_MODDCTOFISCAL 81 = documento de entrada ligado a serviço específico, provavelmente de maior valor médio
- CD_SERIE 2 = principal série do fluxo comercial de saída
- CD_SERIE 1 = principal série de entradas de 57 e 81

1.3.3 Entrar no bloco operacional

Aqui o foco passa a ser:

- CD_OPERACAO
- TP_OPERACAO
- TP_SITUACAO
- TP_MODDCTOFISCAL

Porque CD_OPERACAO parece ser uma das colunas mais explicativas do cabeçalho.

Pelos cruzamentos, o CD_OPERACAO não parece um identificador aleatório. Ele parece ser um código operacional interno muito consistente, porque quase todo código cai sempre no mesmo padrão de:

- entrada ou saída.
- tipo documental.
- em muitos casos, um comportamento financeiro bem específico.

A melhor evidência disso está na tabela acima:

- vários códigos aparecem 100% em TP_OPERACAO = E
- outros aparecem 100% em TP_OPERACAO = S
- quase nenhum mistura entrada e saída ao mesmo tempo

Isso é ótimo, porque mostra que CD_OPERACAO pode virar uma dimensão muito útil na análise principal.

O cruzamento CD_OPERACAO x TP_OPERACAO x TP_SITUACAO mostra dois blocos muito nítidos.

1. Bloco de entrada (TP_OPERACAO = E)

Esse grupo parece representar:

- devoluções.
- entradas de serviço.
- entradas administrativas.
- ou outras entradas fiscais/operacionais.

2. Bloco de saída (TP_OPERACAO = S)

Esse grupo parece representar:

- vendas.
- saídas comerciais.
- algumas saídas específicas menores.

Então, antes mesmo de entender o significado exato de cada código, o dado já mostra que o CD_OPERACAO está muito alinhado com o sentido da movimentação.

A tabela acima mostra que cada CD_OPERACAO está praticamente amarrado a um único TP_MODALITO_FISCAL.

TP_MODALITO_FISCAL = 55 -> Ficam aqui quase todos os códigos ligados ao fluxo principal de mercadoria, tanto entrada quanto saída.

Isso reforça a hipótese de que o 55 é o documento principal de mercadoria da base.

TP_MODALITO_FISCAL = 57 -> Ficam aqui os grandes códigos de entrada operacionais.

Esse bloco já está com uma cara muito forte de:

- transporte.
- entradas acessórias.
- documentos operacionais de apoio.
- talvez conhecimento de transporte ou similares.

TP_MODALITO_FISCAL = 81 -> Aqui só aparece um registro.

Isso é muito forte. Significa que 1933 e 81 andam quase juntos como uma categoria própria. E como 1933 já lembra o CFOP de serviço, esse bloco pode estar ligado a serviço específico de entrada.

Em resumo: CD_OPERACAO e TP_MODALITO_FISCAL estão quase em relação de “família”.

1.3.4 O que já dá para inferir com bastante segurança

Sem precisar cravar significados oficiais, o dado já sustenta algumas hipóteses fortes.

Hipóteses fortes


- 9998 = principal fluxo de saída comercial
- 46 = devolução / entrada ligada a devolução
- 1933 = serviço de entrada de alto valor, associado ao tipo documental 81
- 1300, 1355, 1600 = fluxos operacionais de entrada associados ao tipo documental 57
- 231, 233, 5110, 5920, 9143 = subfluxos de saída em 55

Hipóteses de atenção

- 499 = entrada de altíssimo valor, pouco volume,
- 9950 = caso isolado muito relevante, provavelmente excepcional
- 1982 = aparece cancelado apenas uma vez, mas com valor alto
- 560 = entrada pequena em volume e alta em valor relativo, merece olhar depois


1.3.5 Quantidade de notas por CD_OPERACAO

O ranking dos códigos de operação por quantidade de notas evidencia a forte concentração em poucos códigos (9998, 1300, 1355, 1600).



1.3.6 VL_TOTALNOTA por CD_OPERACAO

O valor total das notas por código de operação (escala log), destacando que o código 9998 domina o faturamento, enquanto códigos como 499, 1933 e 9950 têm alto valor apesar de baixo volume documental.



1.3.7 Validar a identidade fiscal da nota

`np.int64(455)`

`np.int64(453)`

A leitura mais importante aqui não é só “há duplicados”, mas sim que os duplicados parecem estruturados, não aleatórios.

A tabela por `CD_SERIE` ajuda muito a enxergar isso.

A primeira observação é a concentração. O campo é extremamente dominado por poucas séries:

- 2 → 17.647 notas, 10.641.184,05
- 1 → 10.971 notas, 4.313.741,82
- 10 → 2.882 notas, 146.827,69
- 9 → 1.164 notas, 363.284,60

Só essas quatro séries já concentram praticamente toda a base. Então CD_SERIE não é um campo irrelevante: ele claramente separa grandes blocos documentais.

Agora vem a parte mais interessante: a relação entre série, unicidade e situação.

Na série 2, há 17.647 notas e 17.647 números distintos de NF. - Dentro da série 2, o número da nota não se repete. Isso é muito forte. Mesmo existindo 408 canceladas e 71 excluídas, a numeração continua única. Isso sugere que, nessa série, cancelamento/exclusão não gera reaproveitamento aparente do número.

Na série 1, há 10.971 notas e 10.961 números distintos. - Aqui aparecem 10 repetições líquidas. Não é muito, mas já mostra que a série 1 não é perfeitamente única por NR_NF. E como nela existem 22 notas X, dá para dizer que parte dessas repetições pode estar ligada a documentos excluídos, mas não é uma correspondência perfeita.

Na série 10 há 2.882 notas e 2.438 números distintos. - Diferença de 444. Padrão mais revelador.

E no cruzamento com situação: - 2.438 em E - 444 em X

Essa coincidência é forte demais para ser ignorada. A inferência mais natural é que a série 10 carrega um bloco em que os registros X explicam praticamente toda a não unicidade do NR_NF dentro da série.

Claramente a série 10 parece ter um comportamento em que muitos números válidos convivem com uma versão excluída do mesmo número, ou algum tipo de histórico/reprocessamento documental. Não estou cravando o mecanismo exato, mas o padrão estatístico aponta fortemente para isso.

A série 6 repete esse mesmo desenho em miniatura:

- 4 notas, 3 números distintos, 1 excluída

Ou seja, de novo, a não unicidade parece alinhada com X.

Isso muda bastante a leitura do campo. CD_SERIE não parece ser apenas um atributo formal do documento, ele está ajudando a separar comportamentos de emissão e qualidade cadastral.

Outro ponto bom de observar é o perfil financeiro das séries.

1. A série 2 é a mais pesada em volume e valor. Ela tem cara de série principal de operação. Além do volume gigantesco, é a única com cancelamento em massa relevante (408 em C). Isso normalmente acontece justamente nas séries centrais do negócio.
2. A série 1 também é grande e financeiramente forte, mas muito mais “limpa” em status:
 - sem canceladas

- só 22 excluídas

Ela parece um segundo grande bloco operacional, mais estável que a série 2.

3. A série 10, por outro lado, tem muito volume para pouco valor:

- 2.882 notas
- R\$146.827,69
- O ticket médio é baixo. E junto com o excesso de X, isso faz ela parecer um fluxo mais administrativo, operacional ou documental, e menos um núcleo de faturamento principal.

4. A série 9 chama atenção por ser menor em quantidade, mas relativamente forte em valor. Ela pode ser um fluxo específico com ticket médio mais alto do que a série 10, embora bem menor do que as séries 1 e 2 em volume.

Também vale notar algumas séries estranhas pelo perfil financeiro:

- série 0: 751 notas para só R\$5.281,78
- série 157: 21 notas para R\$581,21
- série 60: 154 notas para R\$16.334,60
- Essas séries pequenas podem representar fluxos muito específicos, ajustes, documentos acessórios ou operações residuais. Ainda não dá para interpretar semanticamente, mas elas claramente não têm o mesmo papel das séries 1, 2 e 10.

A melhor conclusão deste bloco, para mim, é esta:

- CD_SERIE é uma coluna útil, principalmente para segmentar fluxos documentais e detectar padrões de duplicidade/status.


O que ela já mostra com segurança é:

- NR_NF sozinho não serve como chave;
- NR_NF + CD_SERIE ainda não serve;
- NR_NF + CD_SERIE + TP_MODALIDADE quase não melhora;
- a duplicidade está fortemente concentrada em algumas séries, especialmente a 10;
- a série 10 parece ter associação muito forte com registros X;
- a série 2 parece ser a principal série operacional e concentra os cancelamentos;
- a série 1 é grande e relativamente limpa;

Portanto, CD_SERIE é um bom campo para entender comportamento documental, não necessariamente para classificar a operação final.


1.3.8 Quantidade de notas por CD_SERIE

O gráfico evidencia a forte concentração de notas nas séries 2, 1 e 10, que juntas representam praticamente toda a base. A série 2 é a principal série operacional, com mais de 17 mil notas.




1.3.9 VL_TOTALNOTA por CD_SERIE

O valor financeiro total por série, em escala logarítmica. A série 2 domina com mais de R\$ 10 milhões, seguida da série 1 com R\$ 4,3 milhões. As séries menores (0, 157, 60) têm valores residuais.



1.3.10 Heatmap: CD_SERIE x TP_SITUACAO

O cruzamento entre série e situação mostra que a série 2 concentra todos os cancelamentos (C), enquanto a série 10 tem alta proporção de excluídos (X), reforçando a leitura de que cada série possui um comportamento documental distinto.



np.True_

np.True_

np.int64(5)

np.int64(3)

1.3.10.0.1 Nota

Unicidade documental: relevante para métricas finais, mas parcialmente endereçada por enquanto. Após filtrar `TP_SITUACAO = 'E'`, duplicidades caem de forma expressiva, restando poucos casos residuais.

1.4 Avaliando prefixo DT

```
DT_FATURA
datetime64[us]
0
min    2026-03-01
max    2026-07-03
Name: DT_FATURA, dtype: datetime64[us]
DT_FATURA
2026-03-01    0.093183
2026-03-02    4.272322
2026-03-03    2.837861
2026-03-04    1.891907
2026-03-05    1.615180
2026-03-06    1.863670
2026-03-07    0.830180
2026-03-08    0.096007
2026-03-09    5.624894
2026-03-10    2.640199
2026-03-11    2.400181
2026-03-12    2.199695
2026-03-13    6.709211
2026-03-14    1.005252
2026-03-15    0.062122
2026-03-16    5.017790
2026-03-17    3.651098
2026-03-18    3.394138
2026-03-19    3.171062
2026-03-20    3.882645
2026-03-21    0.892302
2026-03-22    0.112950
2026-03-23    4.969786
2026-03-24    4.828599
2026-03-25    4.743887
2026-03-26    2.129101
2026-03-27    2.044389
2026-03-28    1.649065
```

2026-03-29	0.705936
2026-03-30	6.048455
2026-03-31	4.136782
2026-04-01	1.462698
2026-04-06	2.451008
2026-04-07	0.940306
2026-04-08	5.785847
2026-04-09	0.033885
2026-04-13	2.442537
2026-04-15	0.717230
2026-04-17	0.200486
2026-04-22	0.008471
2026-04-23	0.031061
2026-04-28	0.002824
2026-04-29	0.002824
2026-05-04	0.002824
2026-05-06	0.002824
2026-05-12	0.002824
2026-05-20	0.025414
2026-05-29	0.087536
2026-06-18	0.016942
2026-06-25	0.087536
2026-07-02	0.002824
2026-07-03	0.172248

Name: proportion, dtype: float64

=====

DT_CADASTRO

datetime64[us]

0

min 2026-03-02 06:55:49

max 2026-07-03 09:25:55

Name: DT_CADASTRO, dtype: datetime64[us]

DT_CADASTRO

2026-03-02 06:55:49	0.002824
2026-03-02 06:56:00	0.002824
2026-03-02 06:56:07	0.002824
2026-03-02 06:56:15	0.002824
2026-03-02 06:56:23	0.002824

...

2026-07-03 08:38:11	0.002824
2026-07-03 09:25:52	0.005647
2026-07-03 09:25:53	0.002824

```

2026-07-03 09:25:54    0.002824
2026-07-03 09:25:55    0.002824
Name: proportion, Length: 33821, dtype: float64
=====

```

```

DT_EMISSAO
datetime64[us]
0
min    2026-03-01
max    2026-03-31
Name: DT_EMISSAO, dtype: datetime64[us]
DT_EMISSAO
2026-03-01    0.141187
2026-03-02    6.559553
2026-03-03    5.901621
2026-03-04    4.122663
2026-03-05    3.199300
2026-03-06    3.834642
2026-03-07    1.109731
2026-03-08    0.231547
2026-03-09    5.653132
2026-03-10    5.382052
2026-03-11    4.049246
2026-03-12    4.407861
2026-03-13    3.543796
2026-03-14    1.524821
2026-03-15    0.127068
2026-03-16    7.584571
2026-03-17    4.252555
2026-03-18    3.261422
2026-03-19    2.950810
2026-03-20    2.352177
2026-03-21    1.510702
2026-03-22    0.172248
2026-03-23    4.825775
2026-03-24    3.315073
2026-03-25    3.052465
2026-03-26    2.171458
2026-03-27    2.439713
2026-03-28    2.225109
2026-03-29    1.634947
2026-03-30    4.693059
2026-03-31    3.769696

```

Name: proportion, dtype: float64

=====

DT_SAIDAENTRADA

datetime64[us]

0

min 2026-03-01

max 2026-07-03

Name: DT_SAIDAENTRADA, dtype: datetime64[us]

DT_SAIDAENTRADA

2026-03-01	0.093183
2026-03-02	4.289264
2026-03-03	2.843508
2026-03-04	1.922968
2026-03-05	1.623652
2026-03-06	1.866493
2026-03-07	0.835828
2026-03-08	0.096007
2026-03-09	5.644660
2026-03-10	2.654318
2026-03-11	2.436889
2026-03-12	2.177105
2026-03-13	6.717682
2026-03-14	1.005252
2026-03-15	0.064946
2026-03-16	4.952844
2026-03-17	3.628508
2026-03-18	3.382843
2026-03-19	3.165415
2026-03-20	3.885469
2026-03-21	0.892302
2026-03-22	0.115773
2026-03-23	4.944372
2026-03-24	4.825775
2026-03-25	4.749534
2026-03-26	2.123454
2026-03-27	2.047213
2026-03-28	1.649065
2026-03-29	0.705936
2026-03-30	6.048455
2026-03-31	4.249732
2026-04-01	1.352572
2026-04-06	2.451008

2026-04-07	0.940306
2026-04-08	5.783024
2026-04-09	0.028237
2026-04-13	2.442537
2026-04-15	0.717230
2026-04-17	0.200486
2026-04-22	0.008471
2026-04-23	0.031061
2026-04-28	0.002824
2026-04-29	0.002824
2026-05-04	0.002824
2026-05-06	0.002824
2026-05-12	0.002824
2026-05-20	0.025414
2026-05-29	0.087536
2026-06-18	0.016942
2026-06-25	0.087536
2026-07-02	0.002824
2026-07-03	0.172248

Name: proportion, dtype: float64

=====

DT_FATURA

QTD_NOTAS VL_TOTALNOTA

DT_FATURA

2026-03-01	33	8726.70
2026-03-02	1513	1168687.92
2026-03-03	1005	732282.53
2026-03-04	670	591429.77
2026-03-05	572	668887.81

...

QTD_NOTAS VL_TOTALNOTA

DT_FATURA

2026-05-29	31	1967.54
2026-06-18	6	475.79
2026-06-25	31	1264.01
2026-07-02	1	44.53
2026-07-03	61	3910.21

DT_EMISSAO

QTD_NOTAS VL_TOTALNOTA

DT_EMISSAO

2026-03-01	50	98789.67
2026-03-02	2323	1365833.23
2026-03-03	2090	864146.39
2026-03-04	1460	1041935.59
2026-03-05	1133	644507.16
...		

	QTD_NOTAS	VL_TOTALNOTA
DT_EMISSAO		
2026-03-27	864	310023.85
2026-03-28	788	227739.77
2026-03-29	579	79279.68
2026-03-30	1662	626045.04
2026-03-31	1335	1104363.39

	QTD_NOTAS	VL_TOTALNOTA
DT_SAIDAENTRADA		
DT_SAIDAENTRADA		
2026-03-01	33	8726.70
2026-03-02	1519	1276755.32
2026-03-03	1007	733091.08
2026-03-04	681	994471.18
2026-03-05	575	681438.32
...		

	QTD_NOTAS	VL_TOTALNOTA
DT_SAIDAENTRADA		
2026-05-29	31	1967.54
2026-06-18	6	475.79
2026-06-25	31	1264.01
2026-07-02	1	44.53
2026-07-03	61	3910.21

1.4.0.1 Data base - Relatório de Faturamento

Para seguir com a análise, a data de referência utilizada no relatório vai ser DT_FATURA.

1.5 Avaliando prefixo VL

VL_TOTALNOTA	15653165.12
VL_TOTALPRODUTO	15148351.13
VL_BASEICMS	10437771.43
VL_ICMS	1193619.50

VL_FRETE	504468.34
VL_DESCONTO	2508.95
VL_DESPACESSOR	345.65
VL_SEGURO	0.00
VL_IPI	0.00
VL_BASEICMSSUBS	0.00
VL_ICMSSUBST	0.00

dtype: float64

1.5.1 O que esse bloco financeiro já mostrou?

Há um padrão muito importante aqui:

- $VL_TOTALNOTA = 15.653.165,12$
- $VL_TOTALPRODUTO = 15.148.351,13$

A diferença é: $R\$15.653.165,12 - R\$15.148.351,13 = R\$504.813,99$

E isso bate exatamente com:

- $VL_FRETE = 504.468,34$
- $VL_DESPACESSOR = 345,65$

Somando: $R\$504.468,34 + R\$345,65 = R\$504.813,99$

Aparentemente, nessa base:

- $VL_TOTALNOTA = VL_TOTALPRODUTO + VL_FRETE + VL_DESPACESSOR$

E o mais importante: $VL_DESCONTO$ não entra nessa composição final.

Ao longo do tratamento dessa base de dados, identifiquei que ou o desconto já foi absorvido antes, provavelmente no valor do produto ou do item.

Como o total de desconto é só: $VL_DESCONTO = 2.508,95$, em uma base de mais de 15,6 MM, ele é financeiramente muito pequeno.


Além disso:

- $VL_SEGURO = 0$
- $VL_IPI = 0$
- $VL_BASEICMSSUBS = 0$
- $VL_ICMSSUBST = 0$

$VL_BASEICMS$ mostra o volume para a base de calculo do ICMS enquanto VL_ICMS mostra o valor real do imposto.

1.5.2 Soma das colunas de valor (VL)

O gráfico abaixo mostra a soma de cada coluna com prefixo VL, evidenciando a composição financeira da base. VL_TOTALNOTA e VL_TOTALPRODUTO dominam o volume, enquanto VL_FRETE tem peso intermediário, VL_DESCONTO e VL_DESPACESSOR são praticamente marginais, e VL_SEGURO, VL_IPI, VL_BASEICMSSUBS e VL_ICMSSUBST são zero.




1.5.3 Avaliando candidato para análise do faturamento

```
np.int64(0)
```

```
np.int64(0)
```


1.5.4 Quantidade de notas por CD_OPERACAO no recorte de faturamento

No recorte candidato ao faturamento (TP_SITUACAO = 'E' e TP_OPERACAO = 'S'), o gráfico abaixo mostra como as notas se distribuem por código de operação, evidenciando o domínio do código 9998 (principal fluxo de saída comercial).



1.5.5 VL_TOTALNOTA por CD_OPERACAO no recorte de faturamento

O valor total das notas no recorte de faturamento, agrupado por CD_OPERACAO, permitindo visualizar o peso financeiro de cada código operacional.



2 Conclusão

- A análise exploratória do cabeçalho de notas fiscais permitiu identificar os campos mais relevantes para a construção do relatório final e estabelecer uma base consistente para a etapa analítica principal.
- A coluna TP_SITUACAO se mostrou essencial para definir o universo válido de análise. Os registros em situação E representam o conjunto efetivamente aproveitável, enquanto os status C e X devem ficar fora da apuração principal, pois introduzem distorções na contagem documental e no faturamento.
- No aspecto operacional, TP_OPERACAO e CD_OPERACAO apresentaram alto poder explicativo. O comportamento observado indica uma separação clara entre entradas e saídas, o que contribui para distinguir o fluxo principal de faturamento dos demais movimentos da base, como devoluções e operações acessórias.
- A análise de unicidade documental mostrou que, embora existam duplicidades na base completa, esse problema desaparece no recorte candidato ao faturamento. No subconjunto com TP_SITUACAO = 'E' e TP_OPERACAO = 'S', não foram identificadas duplicidades nem pela combinação NR_NF + CD_SERIE, nem por NR_NF + CD_SERIE + TP_MODALIDADEFISCAL. Isso torna esse recorte adequado para cálculo de quantidade de notas distintas e ticket médio por nota.
- Na dimensão temporal, DT_FATURA foi identificada como a melhor referência para o relatório. Diferentemente de DT_EMISSAO, que se concentra apenas em março, DT_FATURA acompanha o ciclo efetivo de faturamento observado na base e, por isso, é a coluna mais apropriada para a análise de evolução diária.
- Do ponto de vista financeiro, VL_TOTALNOTA se mostrou a melhor candidata para representar o valor final da nota no cabeçalho. A composição dos valores indica que esse campo reflete principalmente VL_TOTALPRODUTO, VL_FRETE e VL_DESPACESSOR, enquanto descontos e outros componentes fiscais têm impacto reduzido ou irrelevante na apuração principal.
- A análise também permitiu definir, de forma provisória e consistente, o recorte candidato ao faturamento bruto: notas com TP_SITUACAO = 'E' e TP_OPERACAO = 'S'. Dentro desse conjunto, todas as notas pertencem ao TP_MODALIDADEFISCAL = 55, reforçando a interpretação de que esse é o modelo documental central do faturamento de saída.

- Por fim, as colunas relacionadas à empresa não agregam segmentação neste conjunto analisado, pois apresentam um único valor ao longo da base. Assim, para este recorte específico, o relatório por empresa não exigirá particionamento adicional.
- Com isso, considera-se concluída a análise exploratória do cabeçalho do NF. Os resultados obtidos já são suficientes para avançar para a etapa principal do trabalho, com foco na definição final das regras de faturamento bruto e líquido e na integração com o nível de itens para análise de quantidades e produtos.